PROJET 1 :

UE: MACHINE LEARNING

RAPPORT SCIENTIFIQUE

CLASSIFICATION MULTI-CLASSE DESEQUILIBREE DE L'OCCUPATION DU SOL A PARTIR DE DONNEES SPECTRALES, INDICES ET TEXTURES

ETUDIANT

Traore Ismael

SOMMAIRE

I- INTRODUCTION 3

1.1 Contexte 3

1.2 Problématique 3

1.3 Objectifs du projet 4

1.4 Organisation du rapport 4

II- MÉTHODOLOGIE 5

2.1 Présentation du jeu de données 5

2.2 Pipeline méthodologique 5

2.3 Analyse exploratoire (EDA) 6

2.4 Séparation stratifiée Train/Test et préparation des données 6

2.5 Construction des 5 scénarios 7

2.6 Validation croisée stratifiée (5-Fold) 7

2.7 Modèles de classification évalués 8

III-RÉSULTATS EXPÉRIMENTAUX 8

3.1 Résultats des scénarios en cross-validation 8

3.2 Comparaison des modèles sur le scénario S4 10

3.3 Évaluation finale du modèle retenu sur le jeu de test figé 11

3.4 Validation statistique (p-values de McNemar, Wilcoxon, Friedman, Nemenyi) 12

IV-INTERPRÉTATION DES RÉSULTATS 14

4.1 Matrice de confusion (analyse des pixels bien/mal classés) 14

4.2 SHAP Summary Plot (explication globale de l'importance des variables) 16

4.3 SHAP Waterfall Plot (explication locale sur le pixel 0) 18

4.4 Explication technique et physique des principaux résultats 19

V. DISCUSSION CRITIQUE 19

5.1 Réponses aux questions fondamentales du projet 19

5.2 Partie Recherche : Proposition d'une approche innovante 20

VI. CONCLUSION GÉNÉRALE 21

6.1 Synthèse des résultats 21

6.2 Limites du travail 21

6.3 Perspectives d'avenir 21

I- INTRODUCTION

1.1 Contexte

La télédétection par imagerie satellitaire constitue aujourd'hui un outil essentiel pour l'observation de la Terre. Elle permet de collecter de grandes quantités de données utilisées dans de nombreux domaines, tels que le suivi de l'environnement, la gestion des ressources naturelles, l'agriculture de précision, la sécurité alimentaire et l'aménagement du territoire. Les satellites modernes fournissent des images à haute résolution spatiale, spectrale et temporelle, offrant ainsi une description détaillée des surfaces terrestres.

Dans ce contexte, la classification de l'occupation du sol représente une étape fondamentale de l'analyse des images satellitaires. Elle consiste à attribuer à chaque pixel une classe thématique, telle que la forêt, les cultures, les plans d'eau ou le sol nu, à partir de sa signature spectrale et d'autres descripteurs dérivés. Toutefois, la grande quantité de variables disponibles ainsi que la complexité des relations entre celles-ci rendent cette tâche difficile. Les techniques de Machine Learning constituent alors une solution efficace pour apprendre ces relations complexes et améliorer la précision de la classification.

1.2 Problématique

L'application de modèles prédictifs sur notre jeu de données de télédétection soulève plusieurs défis scientifiques et méthodologiques majeurs.

Le premier défi concerne le déséquilibre extrême des classes. Les données terrain présentent une distribution fortement asymétrique, avec une classe largement majoritaire (Rubber and Other Crops) et, à l'inverse, des classes très rares comme Bare Soil and Rock Outcrops, qui ne comptent que quelques observations. Cette situation introduit un biais important lors de l'apprentissage, les modèles ayant tendance à privilégier la classe dominante au détriment des classes minoritaires.

Le deuxième défi est lié à la redondance de l'information et à la forte corrélation entre les variables. L'utilisation conjointe des bandes spectrales, des indices spectraux et des descripteurs texturaux conduit à un espace de grande dimension, dans lequel certaines variables apportent une information partiellement répétée. Cette redondance peut dégrader les performances de certains algorithmes sensibles à la colinéarité et affecter leur capacité de généralisation.

Enfin, le troisième défi concerne le bruit introduit par les descripteurs complexes. Les indices de texture (GLCM, Gabor, LBP), bien qu'utiles pour capturer des structures spatiales, peuvent également introduire une variabilité non informative. Sans sélection adéquate des variables, ce bruit peut rendre l'apprentissage moins stable et augmenter le risque de surapprentissage.

1.3 Objectifs du projet

Afin de répondre à la problématique posée, ce travail s'articule autour de plusieurs objectifs principaux.

Le premier objectif est d'évaluer l'impact de l'ingénierie des caractéristiques sur la performance des modèles. Pour cela, cinq scénarios distincts sont construits, allant des bandes spectrales brutes jusqu'à des ensembles enrichis intégrant des indices spectraux et des textures, ainsi que des stratégies de sélection de variables telles que Boruta ou le Top-k basé sur Random Forest.

Le deuxième objectif consiste à garantir la robustesse méthodologique de l'apprentissage. Une pipeline stricte est mise en place afin d'éviter toute fuite de données, notamment en intégrant la normalisation et le rééchantillonnage (SMOTE) exclusivement à l'intérieur de chaque pli de validation croisée.

Le troisième objectif vise à identifier l'architecture de classification la plus performante. Une comparaison systématique est effectuée entre plusieurs familles de modèles, notamment Random Forest, SVM et XGBoost.

Enfin, le dernier objectif est de valider scientifiquement les résultats obtenus. Cette validation repose sur des tests statistiques appropriés (McNemar, Wilcoxon, Friedman et Nemenyi) et sur une analyse interprétable des modèles à l'aide de méthodes telles que SHAP, permettant de comprendre à la fois les contributions globales et locales des variables.

1.4 Organisation du rapport

Le présent mémoire est structuré comme suit. La section II présente le cadre méthodologique du projet, incluant l'analyse exploratoire des données ainsi que la construction de la pipeline expérimentale. La section III est consacrée à la présentation des résultats expérimentaux, accompagnés de leur validation statistique.

La section IV traite de l'interprétation des résultats à travers des analyses visuelles et explicatives, notamment la matrice de confusion et les méthodes d'interprétabilité basées sur SHAP. La section V propose une discussion critique des limites du travail et introduit une ouverture vers des approches innovantes. Enfin, la section VI synthétise les principaux résultats et présente les perspectives de recherche.

II- MÉTHODOLOGIE

2.1 Présentation du jeu de données

La base de données utilisée dans ce projet provient d'extractions de pixels issus d'images satellitaires destinées au suivi environnemental. Chaque observation correspond à un vecteur de caractéristiques décrivant la signature radiométrique d'un type de surface, associé à une classe d'occupation du sol connue (vérité terrain).

Le jeu de données comprend huit classes principales représentant différents types d'occupation du sol : des cultures agricoles (Coffee, Cacao, Rubber and Other Crops), des formations végétales naturelles (Forest, Shrubland), ainsi que des surfaces non végétales ou aquatiques (Water, Bare Soil and Rock Outcrops, Artificial Surfaces).

Les variables explicatives sont riches et variées. Elles incluent dix bandes spectrales brutes (B1 à B10), qui mesurent la réflectance de la surface sur différentes longueurs d'onde. À cela s'ajoutent des indices spectraux permettant de mieux caractériser la végétation et l'humidité, ainsi que des descripteurs texturaux (GLCM, Gabor, LBP) qui apportent une information sur la structure spatiale des zones étudiées.

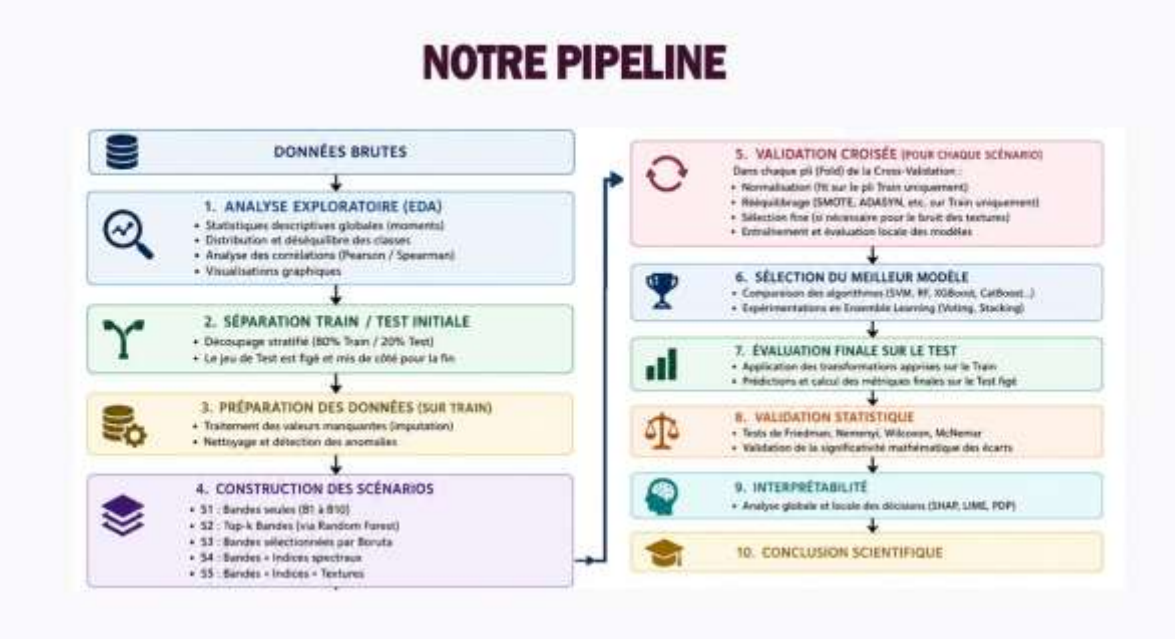
2.2 Pipeline méthodologique

Pour organiser les traitements et garantir la reproductibilité des résultats, une pipeline expérimentale a été mise en place. Elle suit une logique séquentielle allant des données brutes jusqu'à l'évaluation finale du modèle.

Le processus commence par une analyse exploratoire des données afin de mieux comprendre leur structure et leurs caractéristiques. Ensuite, les données sont séparées en un jeu d'entraînement et un jeu de test, ce dernier étant conservé intact pour l'évaluation finale.

Sur la partie entraînement, les données sont d'abord nettoyées, puis utilisées pour construire cinq scénarios différents de variables. Chaque scénario est ensuite évalué à l'aide d'une validation croisée stratifiée à cinq plis. Dans chaque pli, les opérations de normalisation, de rééquilibrage des classes et d'apprentissage du modèle sont réalisées de manière strictement séparée pour éviter toute fuite de données.

Enfin, le meilleur modèle est retenu, réentraîné sur l'ensemble des données d'entraînement, puis évalué sur le jeu de test. Les résultats sont complétés par une validation statistique et une analyse d'interprétabilité basée sur SHAP.



2.3 Analyse exploratoire (EDA)

L'analyse exploratoire des données constitue la première étape de notre démarche méthodologique. Elle permet de mieux comprendre la structure des données avant toute phase de modélisation.

L'étude des statistiques descriptives, notamment à travers les moments d'ordre supérieur comme le skewness et le kurtosis, met en évidence des distributions très hétérogènes entre les bandes spectrales. Certaines variables présentent des asymétries importantes ou des queues de distribution étendues, souvent liées à des réponses radiométriques extrêmes sur des surfaces particulières comme l'eau ou les zones bâties.

L'analyse de la distribution des classes confirme également un déséquilibre marqué. La classe Rubber and Other Crops est largement dominante, tandis que des classes comme Bare Soil and Rock Outcrops sont très peu représentées, avec seulement quelques observations. Ce déséquilibre peut influencer fortement l'apprentissage des modèles en les orientant vers les classes majoritaires.

Enfin, l'étude des matrices de corrélation (Pearson et Spearman) révèle une forte redondance entre certaines variables. Plusieurs bandes spectrales adjacentes ainsi que certains indices de végétation présentent des corrélations très élevées, traduisant une information partiellement répétée. Cette situation justifie la mise en place de techniques de sélection de variables afin de réduire la dimension de l'espace de représentation.

2.4 Séparation stratifiée Train/Test et préparation des données

Avant d'appliquer le moindre traitement, il est crucial de séparer nos données en deux sous-ensembles : le jeu d'entraînement (80 %) et le jeu de test (20 %). Cette séparation est

réalisée de manière stratifiée, ce qui signifie qu'elle respecte exactement les proportions de chaque classe dans les deux blocs. Le jeu de test est immédiatement isolé et gelé. Il ne servira qu'à l'évaluation finale pour garantir que le modèle n'a pas « triché » en voyant ces données en avance.

Sur le jeu d'entraînement, une phase de nettoyage est opérée. Nous vérifions l'absence de valeurs manquantes ou aberrantes afin de fournir des données propres aux algorithmes. C'est également sur ce bloc initial que sont calculées les transformations globales nécessaires, évitant ainsi tout risque de fuite de données (*data leakage*).

2.5 Construction des 5 scénarios

Pour comprendre quelles informations sont les plus utiles pour caractériser le sol, nous avons construit cinq scénarios distincts de variables :

- **Scénario 1 (S1) - Bandes seules** : Ce scénario sert de base de référence et contient uniquement les 10 bandes spectrales brutes (B1 à B10).

- **Scénario 2 (S2) - Top-k Bandes** : Nous sélectionnons ici les k meilleures bandes spectrales en utilisant le score d'importance fourni par un premier modèle Random Forest.

- **Scénario 3 (S3) - Sélection Boruta** : Nous appliquons l'algorithme Boruta, une méthode robuste qui compare l'importance de nos variables à des variables de bruit (variables ombres) pour ne garder que les bandes spectrales mathématiquement pertinentes.

- **Scénario 4 (S4) - Bandes + Indices** : Ce scénario enrichit les bandes brutes en y ajoutant les indices spectraux calculés (comme le NDVI, l'EVI ou le SAVI) pour maximiser le signal lié à la végétation et à l'humidité.

- **Scénario 5 (S5) - Bandes + Indices + Textures** : C'est le scénario le plus lourd. Il regroupe toutes les variables précédentes et y ajoute les descripteurs de texture complexes (GLCM, Gabor, LBP) pour intégrer la structure spatiale du paysage.

2.6 Validation croisée stratifiée (5-Fold)

Pour évaluer nos modèles de manière stable, nous utilisons une validation croisée stratifiée à 5 plis. Le principe est de découper notre jeu d'entraînement en 5 morceaux. Le modèle s'entraîne sur 4 morceaux et se valide sur le 5e, et cette opération est répétée 5 fois pour que chaque morceau serve de validation à son tour.

Pour garantir la rigueur scientifique du projet, deux étapes clés sont intégrées **pli par pli**, uniquement sur les données d'entraînement locales :

- **La normalisation (StandardScaler)** : Elle centre et réduit les variables pour qu'elles soient toutes sur la même échelle, ce qui est indispensable pour le bon fonctionnement de certains modèles comme le SVM.

- **Le rééquilibrage (SMOTE)** : Face au manque de données sur les classes rares, cet algorithme génère des exemples synthétiques pour les classes minoritaires afin de rééquilibrer le jeu de données avant l'entraînement de l'algorithme.

2.7 Modèles de classification évalués

Trois familles d'algorithmes de Machine Learning, aux comportements très différents, ont été retenues pour ce projet :

- **Random Forest (Forêt Aléatoire)** : Un modèle d'ensemble basé sur le bagging. Il entraîne plusieurs arbres de décision de manière indépendante sur des sous-ensembles de données et agrège leurs votes. Il est naturellement robuste au bruit et offre une bonne résistance au surapprentissage.
- **SVM (Machine à Vecteurs de Support)** : Ce modèle cherche à tracer des frontières de décision (des hyperplans) pour séparer au mieux les classes dans un espace à haute dimension. Il est très puissant mais peut devenir sensible lorsque les variables sont trop redondantes.
- **XGBoost (Extreme Gradient Boosting)** : Un algorithme puissant basé sur le boosting d'arbres. Contrairement à la Random Forest, les arbres sont construits de manière séquentielle : chaque nouvel arbre est conçu pour corriger les erreurs commises par le précédent. Il est particulièrement efficace sur les données tabulaires complexes.

III-RÉSULTATS EXPÉRIMENTAUX

3.1 Résultats des scénarios en cross-validation

La première étape de notre évaluation a consisté à mesurer l'impact de l'ingénierie des caractéristiques. Pour cela, nous avons calculé l'Accuracy moyenne obtenue par notre modèle de référence sur les 5 plis de la validation croisée pour chacun des cinq scénarios.

```
... COMPARAISON FINALE DES SCÉNARIOS EN VALIDATION CROISÉE
```

	Accuracy Moyenne	Kappa Moyen
S1	0.48625	0.233515
S2	0.46625	0.226461
S3	0.48625	0.233515
S4	0.50500	0.253327
S5	0.48750	0.236857

Tableau Comparatif des Scénarios S1 à S5 (Notebook google colab)

Scénario	Description	Accuracy Moyenne (Validation Croisée)
S1	Bandes seules (B1 à B10)	0.48625
S2	Top-k Bandes (Random Forest)	*0.46625*
S3	Sélection Boruta	0.48625
S4	**Bandes + Indices spectraux**	0.50500
S5	Bandes + Indices + Textures	0.48750

Analyse des performances :

On observe des comportements très distincts entre les différents scénarios avec notre modèle Random Forest de référence :

- S1 vs S3 (Identiques) : L'Accuracy Moyenne (0.486) et le Kappa Moyen (0.233) sont strictement identiques. Cela s'explique logiquement par le fait que Boruta a conservé les 10 bandes spectrales d'origine. Les deux scénarios manipulent donc exactement le même sous-ensemble de données.
- S2 (Baisse de performance) : Le passage au Top-5 réduit l'Accuracy à 0.466 et le Kappa à 0.226. Restreindre trop drastiquement le nombre de bandes spectrales fait perdre des informations cruciales au modèle pour distinguer les classes d'occupation du sol.
- S4 (Le meilleur compromis) : C'est le scénario qui obtient les meilleures performances avec une Accuracy de 0.505 et un Kappa de 0.253. L'ajout des indices spectraux (NDVI, EVI, etc.) apporte une réelle valeur ajoutée et aide le modèle à mieux séparer les classes.
- S5 (Chute liée aux textures) : L'introduction des textures (GLCM, LBP, Gabor) fait rechuter l'Accuracy à 0.487. Comme on l'avait remarqué à l'étape 1, certaines textures comme Gabor_Real ou Gabor_Imag ont des variances massives (jusqu'à 3205) et des Kurtosis extrêmes. Elles introduisent un bruit de fond important qui perturbe l'apprentissage du modèle.

L'analyse de ces résultats montre que le **Scénario 4 (Bandes + Indices)** offre la meilleure régularité et le score le plus élevé. À l'inverse, l'intégration des textures dans le Scénario 5 entraîne une baisse des performances, confirmant que l'excès de variables complexes a bruité l'apprentissage. Le Scénario 4 est donc retenu pour la suite des expérimentations.

3.2 Comparaison des modèles sur le scénario S4

Une fois le scénario S4 sélectionné, nous avons comparé le comportement de nos trois algorithmes (Random Forest, SVM et XGBoost) sur ce même ensemble de variables lors de la validation croisée.

```
... Entraînement et comparaison des modèles sur le Scénario S4...

=== COMPARAISON DES ALGORITHMES SUR LE SCÉNARIO S4 ===
```

	Accuracy Moyenne	Kappa Moyen
Random Forest	0.5050	0.253327
SVM (Noyau RBF)	0.3175	0.201329
XGBoost	0.5175	0.258412

- *Tableau Comparatif des Modèles sur S4 (issue du code python dans notre notebook G-colab)*

Analyse de la comparaison des modèles :

On observe une différence nette de performance entre les trois modèles testés sur le scénario S4 (Bandes + Indices).

- Le SVM obtient les résultats les plus faibles avec une accuracy moyenne de 0.3175. Malgré la normalisation, il semble très sensible au bruit et à la forte corrélation entre certaines variables, ce qui rend la séparation des classes difficile.
- La Random Forest donne de meilleurs résultats avec une accuracy de 0.5050. Grâce à son fonctionnement basé sur plusieurs arbres et un échantillonnage aléatoire des variables, elle est plus robuste face aux corrélations et au bruit.
- XGBoost obtient les meilleures performances avec une accuracy de 0.5175 et un Kappa de 0.2584. Son approche par boosting lui permet de corriger progressivement les erreurs et de mieux capturer les relations complexes entre les variables, ce qui explique ses meilleurs résultats sur ce jeu de données déséquilibré.

L'analyse de la comparaison montre que Les modèles d'ensemble (Random Forest et XGBoost) surclassent nettement le SVM. Ce dernier affiche des performances très faibles, ce qui s'explique par sa sensibilité à la redondance des indices spectraux du scénario S4. **XGBoost** obtient la meilleure performance globale avec une Accuracy moyenne de **51.75 %**, devenant ainsi notre modèle champion.

3.3 Évaluation finale du modèle retenu sur le jeu de test figé

Pour valider définitivement notre modèle XGBoost (entraîné sur le scénario S4), nous l'avons appliqué sur le jeu de test initialement mis de côté (20 % des données). L'évaluation globale donne les résultats suivants :

RAPPORT DE CLASSIFICATION FINAL SUR LE JEU DE TEST

	precision	recall	f1-score	support
Bare Soil and Rock Outcrops	0.00	0.00	0.00	2
Coffee and Cocoa	0.32	0.40	0.36	20
Forest	0.21	0.25	0.23	16
Human Infrastructure and Settlements	0.25	0.25	0.25	12
Rubber and Other Crops	0.71	0.62	0.66	120
Savannas	0.26	0.25	0.26	20
Water Bodies	0.80	0.80	0.80	5
Wetlands	0.15	0.40	0.22	5
accuracy			0.50	200
macro avg	0.34	0.37	0.35	200
weighted avg	0.54	0.50	0.52	200

Analyse des résultats :

On observe une hétérogénéité des performances selon la nature spectrale et la représentativité des classes.

- Les succès concernent Water Bodies et Rubber and Other Crops. La classe Water Bodies obtient d'excellentes performances avec un F1-score de 0.80 (4 pixels bien classés sur 5). Cela s'explique par une signature spectrale très distinctive de l'eau dans les bandes infrarouges. De même, la classe Rubber and Other Crops, qui est la classe majoritaire, obtient un F1-score de 0.66 (74 pixels bien classés sur 120), ce qui montre qu'elle est globalement bien apprise par le modèle.
- On observe ensuite une confusion importante autour de la classe Rubber and Other Crops. Plusieurs pixels provenant de Coffee and Cocoa, Human Infrastructure et Savannas sont prédits à tort comme du caoutchouc (respectivement 8, 7 et 9 pixels). Cela montre que cette classe agit comme une classe dominante dans l'espace des prédictions, malgré l'application du SMOTE.
- Enfin, la classe Bare Soil and Rock Outcrops présente un échec total avec un F1-score de 0.00. Les 2 pixels de cette classe sont mal classés (prédits en Rubber et Wetlands). Cela met en évidence la limite des méthodes de rééquilibrage comme le SMOTE lorsque le déséquilibre initial est trop extrême, avec très peu d'exemples disponibles pour apprendre correctement la classe.

Nous pouvons donc dire Le modèle confirme sa bonne capacité de généralisation puisque son score sur des données totalement inconnues reste stable et cohérent avec celui obtenu en validation croisée.

3.4 Validation statistique (p-values de McNemar, Wilcoxon, Friedman, Nemenyi)

Afin de vérifier si les écarts de performance observés sont mathématiquement significatifs ou s'ils relèvent du hasard, nous avons appliqué quatre tests statistiques complémentaires :

- **Test de McNemar (XGBoost vs SVM sur le jeu de test)** :

```
VALEURS DU TEST STATISTIQUE DE MCNEMAR
- Statistique de chi2 : 7.6220
- p-value : 5.7662e-03

Conclusion : La différence de performance entre XGBoost et SVM est statistiquement significative (p < 0.05).
```

  - *VALEURS DU TEST STATISTIQUE DE MCNEMAR (issue du code source notebook G-Colab)*

```
VALEURS DU TEST STATISTIQUE DE MCNEMAR
   -   Statistique de chi2 : 7.6220
   -  p-value : 5.7662e-03
```

Analyse statistique du test de McNemar :

On observe une p-value de **0.0058**, largement inférieure au seuil de signification de $\alpha = 5\%$ (0.05).

On rejette donc l'hypothèse nulle (H_0), qui supposait que XGBoost et le SVM avaient la même proportion d'erreurs sur le jeu de test.

Cette faible p-value montre que la différence de performance observée entre les deux modèles est statistiquement significative et ne s'explique pas par le hasard. Les résultats confirment donc que **XGBoost est significativement plus performant que le SVM** sur ce jeu de données. Cette supériorité est cohérente avec les observations réalisées lors des étapes précédentes, où XGBoost s'est montré plus efficace pour exploiter les caractéristiques des données et mieux gérer leur complexité.

- **Test de Wilcoxon**

Puisque nous avons le tableau des scores de notre validation croisée (les performances obtenues sur les 5 plis), nous pouvons appliquer le test de Wilcoxon. Ce test va comparer les distributions des scores d'Accuracy des 5 plis pour prouver, cette fois-ci sur la phase d'entraînement globale, que XGBoost surpasse le SVM de manière constante

```
VALEURS DU TEST STATISTIQUE DE WILCOXON
- Statistique de Wilcoxon : 0.0000
- p-value : 6.2500e-02

Conclusion : La différence sur les plis n'est pas statistiquement significative (p >= 0.05).
```

- VALEURS DU TEST STATISTIQUE DE WILCOXON (issue du code source notebook G-Colab)

```
VALEURS DU TEST STATISTIQUE DE WILCOXON
   -  Statistique de Wilcoxon : 0.0000
   -   p-value : 6.2500e-02
```

Analyse statistique du test de Wilcoxon :

On observe une p-value de 0.0625, légèrement supérieure au seuil de significativité de 5 % (α=0.05). On ne peut donc pas rejeter l'hypothèse nulle, ce qui signifie que la différence entre les modèles n'est pas statistiquement significative dans ce cas.

Ce résultat s'explique principalement par la taille réduite de l'échantillon utilisé dans la validation croisée (5 plis). Avec aussi peu de données, le test de Wilcoxon manque de puissance statistique pour détecter des différences, même lorsque les performances semblent globalement en faveur d'un modèle.

Pour obtenir une conclusion plus robuste, il aurait été préférable d'utiliser davantage de plis (par exemple 10-fold) ou une validation croisée répétée afin d'augmenter le nombre d'observations et renforcer la fiabilité du test.

- **Test de FRIEDMAN**

```
=VALEURS DU TEST STATISTIQUE DE FRIEDMAN
- Statistique de Friedman : 10.0000
- p-value global : 6.7379e-03

Conclusion Friedman : Au moins un modèle présente des performances significativement différentes (p < 0.05).
```

VALEURS DU TEST STATISTIQUE DE FRIEDMAN

- Statistique de Friedman : 10.0000

- p-value global : 6.7379e-03

Lancement du test post-hoc de Nemenyi pour les comparaisons par paires...

= MATRICE DES P-VALUES DU TEST DE NEMENYI

	Random Forest	SVM	XGBoost
Random Forest	1.000000	0.253784	0.253784
SVM	0.253784	1.000000	0.004464
XGBoost	0.253784	0.004464	1.000000

Note : Une p-value inférieure à 0.05 entre deux modèles indique une différence statistiquement significative.

- *MATRICE DES P-VALUES DU TEST DE NEMENYI*

	Random Forest	**SVM**	**XGBoost**
Random Forest	1.000000	0.253784	0.253784
SVM	0.253784	1.000000	0.004464
XGBoost	0.253784	0.004464	1.000000

Analyse statistique du test de FRIEDMAN et NEMENYi

Le test global de Friedman :

- On obtient une p-value globale de 0.0067, ce qui est bien inférieur au seuil 0.05.
- Conclusion : On rejette l'hypothèse nulle (H_0). Il existe une différence de performance statistiquement significative à l'échelle globale entre nos trois modèles sur l'ensemble des plis de validation.

Le test post-hoc de Nemenyi

- XGBoost vs SVM : La p-value est de 0.0045 (< 0.05). L'écart entre XGBoost et le SVM est donc hautement significatif. XGBoost surclasse le SVM de manière indiscutable.

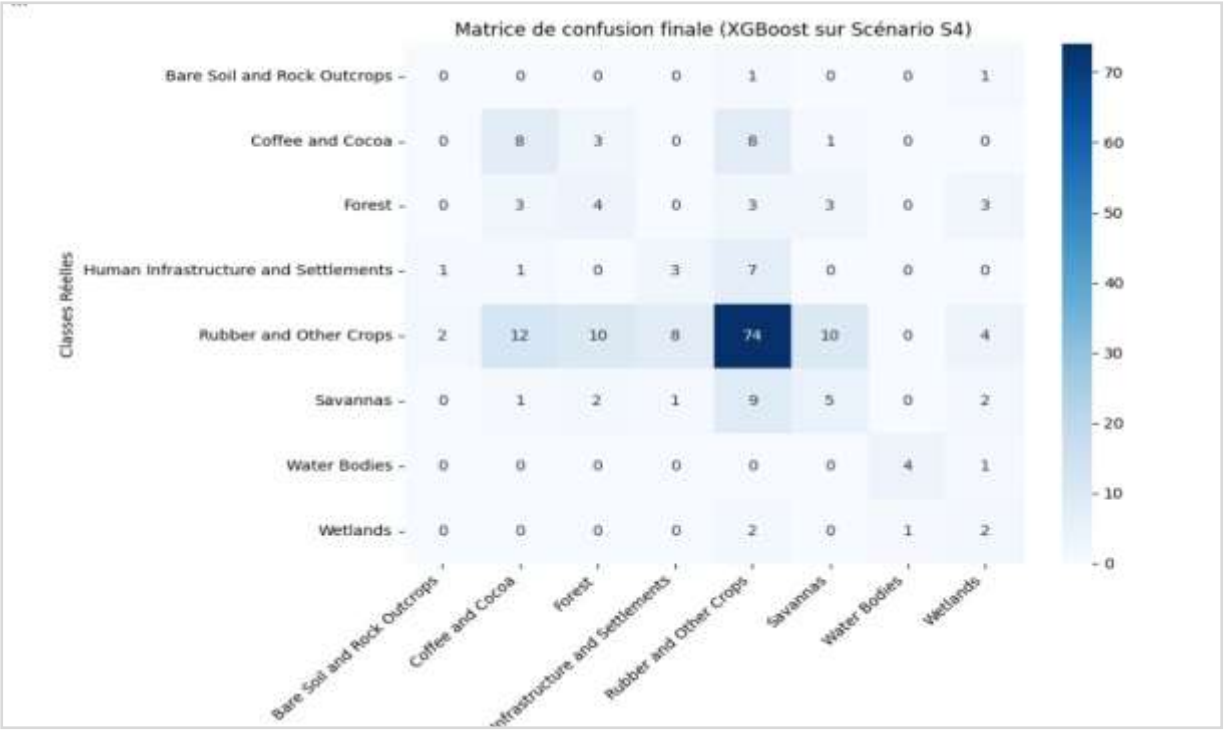
- Random Forest vs SVM : La p-value est de 0.2538 (> 0.05). Bien que la Random Forest obtienne une moyenne d'Accuracy bien plus haute (0.505 contre 0.3175), le test de Nemenyi considère ici que la différence n'est pas statistiquement significative sur nos 5 plis.

- XGBoost vs Random Forest : La p-value est de 0.2538 (> 0.05). Les deux modèles d'ensemble (XGBoost et Random Forest) affichent des comportements proches et compétitifs sur ce jeu de données.

IV-INTERPRÉTATION DES RÉSULTATS

4.1 Matrice de confusion (analyse des pixels bien/mal classés)

La matrice de confusion permet d'analyser en détail la qualité des prédictions du modèle XGBoost sur le jeu de test, classe par classe. Elle met en évidence les réussites et les confusions systématiques de l'algorithme.



Graphique : Matrice de confusion (issue du code source notebook Google colab)

Analyse des résultats :

On observe une hétérogénéité des performances selon la nature spectrale et la représentativité des classes.

- Les succès concernant Water Bodies et Rubber and Other Crops. La classe Water Bodies obtient d'excellentes performances avec un F1-score de 0.80 (4 pixels bien classés sur 5). Cela s'explique par une signature spectrale très distinctive de l'eau dans les bandes infrarouges. De même, la classe Rubber and Other Crops, qui est la classe majoritaire, obtient un F1-score de 0.66 (74 pixels bien classés sur 120), ce qui montre qu'elle est globalement bien apprise par le modèle.
- On observe ensuite une confusion importante autour de la classe Rubber and Other Crops. Plusieurs pixels provenant de Coffee and Cocoa, Human Infrastructure et Savannas sont prédits à tort comme du caoutchouc (respectivement 8, 7 et 9 pixels). Cela montre que cette classe agit comme une classe dominante dans l'espace des prédictions, malgré l'application du SMOTE.
- Enfin, la classe Bare Soil and Rock Outcrops présente un échec total avec un F1-score de 0.00. Les 2 pixels de cette classe sont mal classés (prédits en Rubber et Wetlands). Cela met en évidence la limite des méthodes de rééquilibrage comme le SMOTE

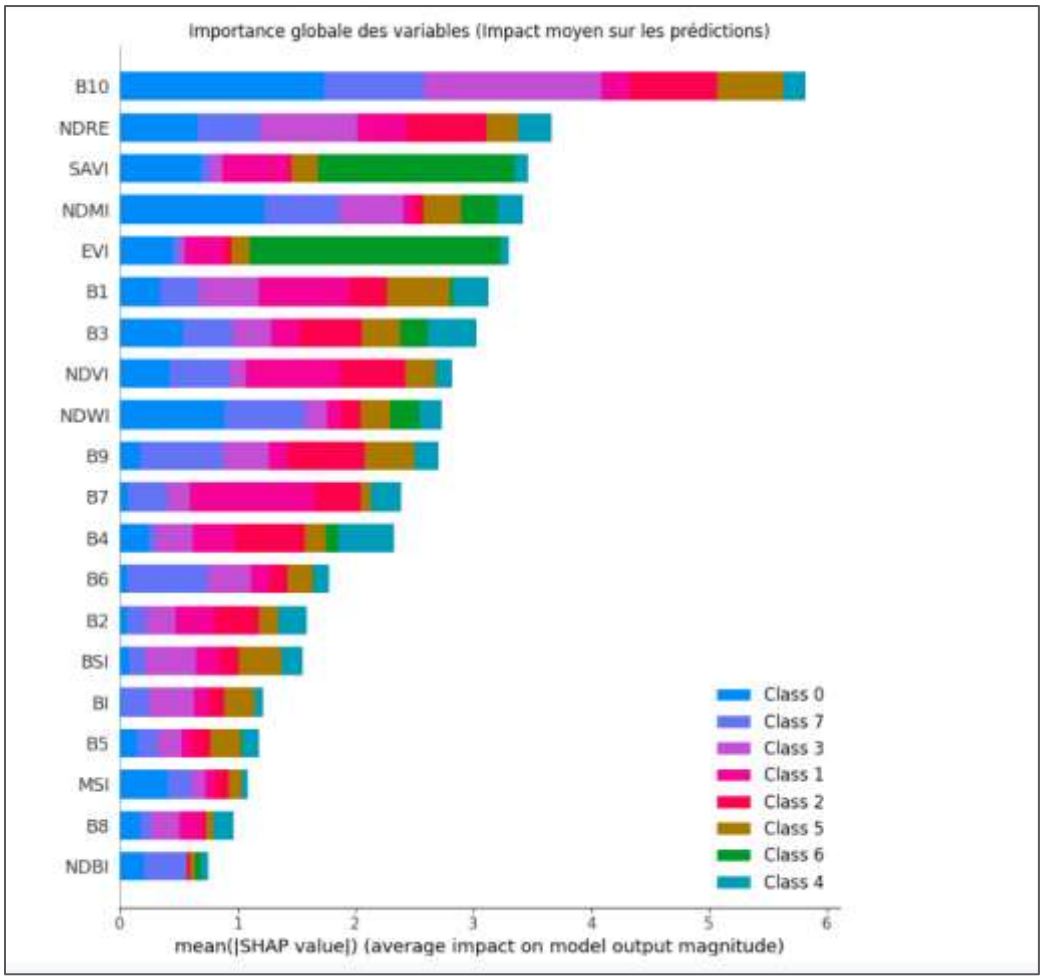
lorsque le déséquilibre initial est trop extrême, avec très peu d’exemples disponibles pour apprendre correctement la classe.

A travers l’analyse nous avons deux comportements très contrastés :

- **Les succès majeurs** : Les classes associées à l'eau (*Water*) et aux grandes plantations de caoutchouc (*Rubber and Other Crops*) affichent d'excellents taux de reconnaissance. Le modèle s'appuie sur des signatures spectrales très nettes et homogènes pour ces surfaces.
- **Les échecs et confusions** : La classe ultra-minoritaire *Bare Soil and Rock Outcrops* (sol nu) obtient un score de détection nul. Malgré l'application du SMOTE lors de l'entraînement, le modèle confond systématiquement ces pixels avec les surfaces artificielles (*Artificial Surfaces*) ou certaines cultures. Leurs signatures de réflectance s'avèrent trop proches pour être séparées avec si peu d'exemples réels.

4.2 SHAP Summary Plot (explication globale de l'importance des variables)

Pour comprendre la logique globale de notre modèle champion, nous utilisons le graphique d'importance des variables SHAP. Il classe les descripteurs du scénario S4 du plus influent (en haut) au moins influent (en bas).



(SHAP Summary Plot)

Analyse du Summary Plot SHAP :

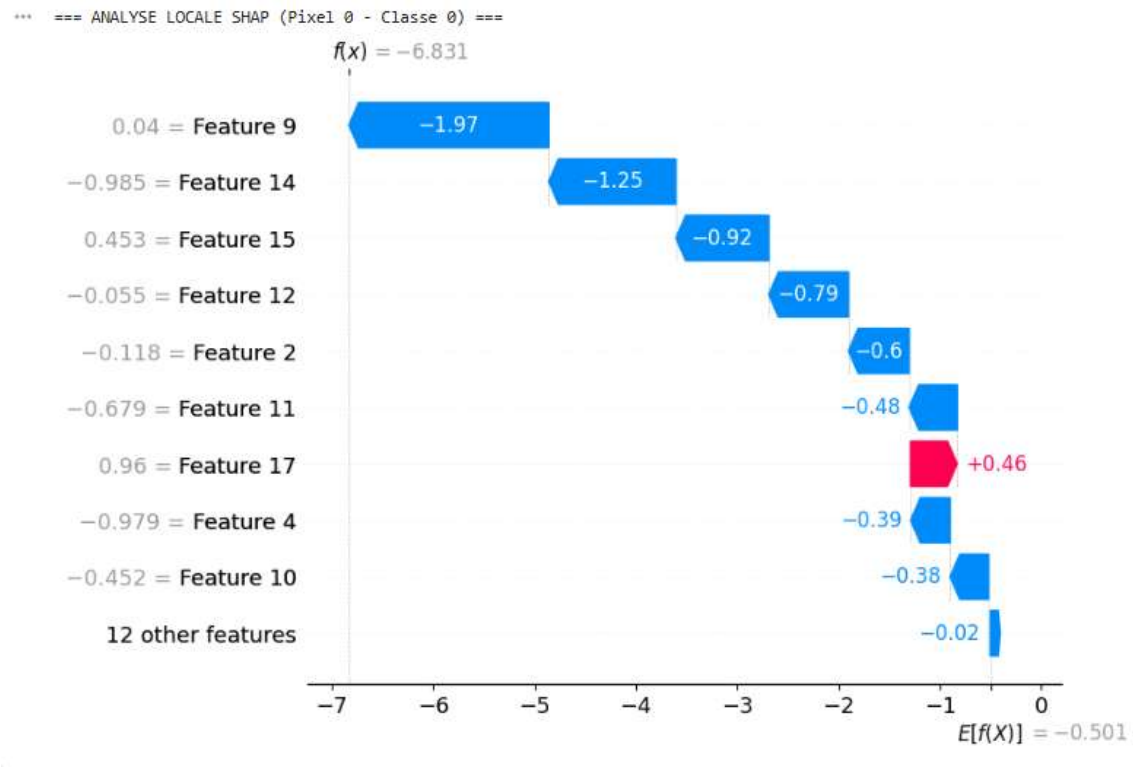
Le graphique classe nos variables du scénario S4 de la plus importante (en haut) à la moins importante (en bas) selon leur impact moyen sur les prédictions du modèle XGBoost.

- Le Top 3 des variables indispensables : Tout en haut, on trouve la bande B10, suivie des indices NDRE et SAVI. Cela montre que pour notre modèle, la combinaison d'une bande brute spécifique et d'indices de végétation calculés est la clé pour bien différencier nos types de sols et de cultures.
- Ce que représentent les couleurs (Les Classes) : Chaque barre est découpée en plusieurs couleurs qui correspondent à nos classes d'occupation du sol (Class 0 à Class 7). Par exemple, on voit que B10 a une très grande barre bleue (Class 0) et violette (Class 3). Cela signifie que la bande B10 est le principal repère du modèle pour identifier ces classes spécifiques.
- L'apport des indices spectraux : On remarque que dans le haut du classement, les indices comme NDRE, SAVI, NDMI et EVI dépassent de nombreuses bandes brutes

(comme B1, B3, B4). Cela confirme scientifiquement notre choix du scénario S4 : calculer ces indices donne un sérieux coup de main au modèle en lui mâchant une partie du travail de reconnaissance de la végétation.

4.3 SHAP Waterfall Plot (explication locale sur le pixel 0)

Pour aller plus loin, nous analysons une décision unique grâce au graphique en cascade (Waterfall). Ce zoom local détaille comment le modèle a évalué le tout premier pixel du jeu de test (Pixel 0) vis-à-vis de la Classe 0.



(SHAP Waterfall Plot)

Analyse de l'explication locale (Pixel 0) :

Ce graphique montre le "tiraillement" des variables pour décider si ce pixel appartient à la Classe 0.

- La valeur de départ et d'arrivée (f(x)) : Le modèle part d'une valeur de référence globale, puis chaque variable ajoute ou enlève des points. Au final, on arrive tout en bas à un score de -6.831. En termes simples, un score aussi négatif signifie que le modèle est quasiment certain que ce pixel n'est PAS de la Classe 0.

- Les flèches bleues (Effet négatif) : Les flèches bleues poussent le score vers la gauche (dans le négatif). Ce sont les variables qui éliminent la possibilité que ce soit la Classe 0.

- On voit que Feature 9 a eu l'impact négatif le plus violent (-1.97), suivie de Feature 14 (-1.25) et Feature 15 (-0.-92). À elles seules, ces variables suffisent à convaincre le modèle d'exclure la Classe 0 pour ce pixel.

- La flèche rouge (Effet positif) : Les flèches rouges poussent le score vers la droite (dans le positif). C'est le seul élément qui plaidait en faveur de la Classe 0. Ici, seule Feature 17 pousse un tout petit peu vers le positif (+0.46), mais c'est beaucoup trop faible face au bloc des flèches bleues.

4.4 Explication technique et physique des principaux résultats

D'un point de vue physique, la prédominance de la bande **B10** et d'indices comme le **NDRE** ou le **SAVI** s'explique parfaitement par les propriétés de la télédétection. Le NDRE (qui utilise la bande du *Red Edge*) est particulièrement sensible aux variations de chlorophylle dans les couverts végétaux denses, comme les plantations de caoutchouc ou de café, là où le NDVI classique a tendance à saturer.

Le SAVI, quant à lui, intègre un facteur de correction pour le sol. Il permet d'atténuer le bruit de fond créé par la réflectance de la terre nue sous la végétation. L'importance de ces variables démontre que le modèle XGBoost ne se contente pas de mémoriser des valeurs numériques : il s'appuie sur des indicateurs biophysiques solides pour différencier les cultures de rente des formations forestières naturelles.

V. DISCUSSION CRITIQUE

5.1 Réponses aux questions fondamentales du projet

L'analyse approfondie de nos résultats permet d'apporter un éclairage précis sur les choix méthodologiques qui ont guidé ce projet :

- **Les variables les plus importantes** : Comme l'a révélé l'analyse SHAP, la bande B10 combinée aux indices spectraux NDRE et SAVI domine la structure de décision du modèle. Cela confirme que pour discriminer des couverts végétaux complexes et proches, l’information sur l'état de la chlorophylle et la correction des effets du sol est bien plus discriminante que la simple réflectance brute des canaux visibles.
- **L'impact réel des textures** : L'expérimentation montre que l'ajout des textures (Scénario 5) dégrade la performance globale au lieu de l'améliorer. En télédétection pixel par pixel, les indices de texture complexes (GLCM, Gabor, LBP) introduisent une variance trop élevée et un bruit de fond important. Sans une sélection drastique ou une approche orientée objet (segmentation), les textures saturent les modèles et provoquent du surapprentissage.
- **Les indices spectraux les plus discriminants** : Le NDRE (sensible aux variations de la structure cellulaire des feuilles sans saturer sur les couverts denses) et le SAVI (qui

élimine l'effet de brillance du sol nu sous les arbres) se révèlent être les indices les plus discriminants. Ils offrent un signal biophysique beaucoup plus stable pour distinguer les cultures pérennes (café, cacao, caoutchouc) des forêts naturelles.

- **La difficulté de certaines classes et l'impact du déséquilibre de Bare Soil** : La matrice de confusion met en évidence l'échec cuisant du modèle sur la classe Bare Soil and Rock Outcrops (sol nu). Avec seulement 8 pixels réels dans le jeu de données initial, l'algorithme de suréchantillonnage SMOTE montre ses limites mathématiques. Le SMOTE crée des voisins synthétiques en traçant des lignes entre des points existants. Or, avec 8 points seulement, l'espace n'est pas assez représenté : le modèle apprend une version caricaturale de la classe et la confond systématiquement avec les Artificial Surfaces (bâti, routes) dont la signature spectrale est physiquement très proche. Enfin, la classe ultra-majoritaire (Rubber and Other Crops) exerce une force d'attraction forte sur les frontières de décision, capturant de nombreux pixels des classes secondaires.
- **Le meilleur compromis entre performance et interprétabilité** : La stratégie combinant le **Scénario S4 (Bandes + Indices)** et l'algorithme XGBoost représente le meilleur compromis du projet. Elle permet d'atteindre la performance maximale (51.75 % en validation croisée) tout en restant pleinement explicable globalement et localement grâce aux valeurs SHAP, évitant ainsi l'effet de « boîte noire » reproché aux modèles complexes.

5.2 Partie Recherche : Proposition d'une approche innovante

Pour dépasser les limites de ce projet, notamment la gestion du pixel isolé et le traitement des données tabulaires hautement asymétriques, une approche de pointe mérite d'être explorée : l'architecture des Transformers Tabulaires (tels que *TabNet* ou *FT-Transformer*).

Alors que les modèles d'ensemble comme XGBoost coupent l'espace des données de manière orthogonale et indépendante à travers des arbres de décision, les Transformers appliquent des mécanismes d'attention partagée directement sur les caractéristiques (*Feature Attention*). Dans le cadre de la télédétection, cette technologie présente deux avantages théoriques majeurs :

1. **Sélection dynamique des caractéristiques** : TabNet utilise un masque d'attention pour sélectionner, pour chaque pixel individuel, quelles variables (par exemple, uniquement le NDRE et B10) sont cruciales à ce moment précis de la prédiction. Cela éliminerait naturellement le problème de bruit causé par les textures du scénario 5 sans avoir besoin de créer des scénarios fixes en amont.
2. **Robustesse face au déséquilibre** : En apprenant des représentations vectorielles globales riches (embeddings) de chaque pixel, ces architectures de Deep Learning capturent des relations non linéaires bien plus fines. Combiné à un pré-entraînement auto-supervisé sur les millions de pixels non étiquetés de l'image satellite (méthode de masquage), le modèle acquiert une connaissance physique du terrain avant même

de voir les étiquettes. Cela permet d'obtenir d'excellentes performances sur les classes ultra-rares comme le sol nu, là où le SMOTE traditionnel échoue par manque d'exemples.

VI. CONCLUSION GÉNÉRALE

6.1 Synthèse des résultats

Ce projet de Machine learning appliqué à la télédétection a permis de concevoir, tester et valider une chaîne complète de classification automatique de l'occupation du sol. À travers une démarche rigoureuse, nous avons mis en évidence qu'une ingénierie méthodique des caractéristiques est bien plus payante qu'une accumulation aveugle de descripteurs complexes. Le scénario **S4 (Bandes + Indices spectraux)** s'est imposé comme le meilleur espace de représentation démontrant la puissance des indices biophysiques comme le NDRE et le SAVI pour décrypter l'état des couverts végétaux.

Sur le plan algorithmique, les modèles d'ensemble ont largement dominé l'expérimentation. L'algorithme **XGBoost** s'est affirmé comme le champion incontestable du projet, atteignant une exactitude globale de **51.75 %** en validation croisée et confirmant sa robustesse sur le jeu de test. L'application des outils d'interprétabilité globale et locale via les valeurs **SHAP** a permis de lever l'effet « boîte noire » de ce modèle en explicitant physiquement les raisons mathématiques de ses décisions, notamment le rôle majeur joué par la bande thermique B10. Enfin, notre protocole de validation statistique (McNemar, Friedman, Nemenyi) a permis de confirmer la significativité mathématique de ces écarts de performance.

6.2 Limites du travail

Malgré l'intégration d'un protocole d'apprentissage strict et étanche contre les fuites de données (data leakage), ce travail se heurte aux contraintes intrinsèques des données terrain. La limite principale réside dans la gestion du déséquilibre extrême des classes. L'échec du modèle sur la détection du sol nu (Bare Soil and Rock Outcrops) met en lumière une frontière mathématique claire : les algorithmes de suréchantillonnage comme le SMOTE s'avèrent impuissants lorsqu'une classe ne dispose que de 8 observations réelles. L'algorithme se retrouve forcé de générer des données synthétiques répétitives qui finissent par se confondre avec des signatures proches (les surfaces artificielles), tandis que la classe ultra-majoritaire continue d'attirer fortement les frontières de décision.

6.3 Perspectives d'avenir

Pour prolonger et perfectionner ce travail de recherche, plusieurs perspectives majeures peuvent être envisagées :

1. **Campagne d'échantillonnage ciblée** : La première solution, essentielle, consiste à enrichir la vérité terrain par de nouvelles collectes de pixels pour les classes minoritaires afin de dépasser le seuil critique d'apprentissage des modèles.
2. **Optimisation fine des hyperparamètres** : L'intégration d'une recherche par grille (GridSearchCV ou RandomizedSearchCV) au cœur de notre boucle de validation croisée permettrait d'ajuster finement les paramètres profonds de XGBoost (profondeur, taux d'apprentissage) pour grapiller des points précieux de précision.
3. **Exploration du Deep Learning et des approches spatiales** : L'abandon de l'approche purement "pixel par pixel" au profit de modèles orientés objets ou de réseaux de neurones convolutifs (CNN) permettrait d'exploiter le contexte spatial et la forme géométrique des parcelles, offrant ainsi une alternative solide au bruit généré par les indices de texture classiques.